


Del dato crudo al consumo – Pipeline de datos

Gobierno y Gestión de datos

Reis y Housley, Fundamentals of Data Engineering. Capítulos 2, 5-9




Ciclo de vida del dato y ciclo de vida de la ingeniería de datos

Los datos ya llegaron, ¿cómo convertimos los datos almacenados en datos útiles?



Fases del ciclo de vida de la ingeniería de datos



Security

Data
management


DataOps

Data
architecture

Orchestration

Software
engineering

Fases del ciclo de vida de la ingeniería de datos



Fases del ciclo de vida de la ingeniería de datos

Mover y almacenar datos todavía no genera un producto

- **Lo que tenemos**

- Datos extraídos de las fuentes
- Archivos o tablas disponibles
- Ejecuciones de ingesta
- Una copia de los datos originales

- **Lo que nos falta**

- Comprender qué representa cada registro
- Corregir problemas de calidad
- Integrar fuentes
- Aplicar reglas de negocio
- Preparar una salida para un consumidor

¿Cómo generamos valor?

Fases del ciclo de vida de la ingeniería de datos

Consultar, modelar y transformar

- **Consultar**

- ¿Qué datos necesito recuperar o calcular?
- Filtrar, unir, ordenar o agregar datos para responder una pregunta

- **Modelar**

- ¿Cómo representar el negocio en los datos?
- Definir entidades, relaciones, claves, grano y significado de los campos.

- **Transformar**

- ¿Qué resultado debemos construir y conservar?
- Genera un nuevo dataset utilizable
- Aplicar definiciones de modelado, e integrar datos y persiste un resultado para nuevos procesos o consumidores.

Fases del ciclo de vida de la ingeniería de datos

Waze necesita estimar el tránsito por segmento

- **¿Qué decisión debe mejorar?**
 - Evitar o penalizar segmentos al calcular una ruta
 - Consumidores: motor de rutas, mapa y alertas
 - Actualización: cada cinco minutos
- **¿Qué producto se necesita?**
 - Estado del tránsito por segmento y ventana temporal (5')
 - Fuentes: eventos GPS, red vial e historia
 - Salida: trafico_segmento_5min
- **Problema de datos**
 - Los eventos GPS individuales no permiten decidir directamente si una calle está congestionada.
 - Hay que convertir observaciones dispersas en un estado actualizado de la red vial.

Fases del ciclo de vida de la ingeniería de datos

El modelo conecta eventos, segmentos y tiempo

- **¿Qué decisión debe mejorar?**
 - Evitar o penalizar segmentos al calcular una ruta
 - Consumidores: motor de rutas, mapa y alertas
 - Actualización: cada cinco minutos
- **¿Qué producto se necesita?**
 - Estado del tránsito por segmento y ventana temporal (5')
 - Fuentes: eventos GPS, red vial e historia
 - Salida: trafico_segmento_5min
- **Problema de datos**
 - Los eventos GPS individuales no permiten decidir directamente si una calle está congestionada.
 - Hay que convertir observaciones dispersas en un estado actualizado de la red vial.

Fases del ciclo de vida de la ingeniería de datos

La transformación construye el estado del tránsito

PREPARAR LOS EVENTOS

Validar coordenadas y velocidades.

Estandarizar timestamps y unidades.

Eliminar eventos duplicados.

INTEGRAR Y AGRUPAR

Asociar cada evento con un segmento vial.

Agrupar por segmento y ventana de cinco minutos.

DERIVAR Y PERSISTIR

Calcular velocidad promedio.

Comparar con el perfil histórico y clasificar.

Guardar
trafico_segmento_5min.

1 • PREPARAR

2 • INTEGRAR

3 • CONSTRUIR

Consultas y modelado

Fases del ciclo de vida de la ingeniería de datos

Las consultas implementan la lógica de una transformación (I)

- Una transformación puede utilizar una o varias consultas
- Cuando el resultado se persiste, pasa a formar parte del producto de datos

Operación SQL	¿Qué hace?	Ejemplo
WHERE	Selecciona observaciones válidas	Excluir velocidades imposibles
JOIN	Integra diferentes fuentes	Asociar GPS con segmento vial e histórico
GROUP BY	Lleva los eventos a la granularidad del producto	Agrupar por segmento y ventana de 5 minutos
AVG, COUNT, CASE	Calcula y clasifica	Velocidad promedio y estado del tránsito
CREATE/INSERT/WRITE	Almacena el resultado	Guardar trafico_segmento_5min

Fases del ciclo de vida de la ingeniería de datos

Las consultas implementan la lógica de una transformación (II)

```
SELECT
  segmento_id,
  ventana_5min,
  AVG(velocidad_kmh) AS velocidad_promedio,
  COUNT(*) AS cantidad_observaciones,
  CASE
    WHEN AVG(velocidad_kmh) < 20 THEN
      'Congestionado'
    WHEN AVG(velocidad_kmh) < 40 THEN 'Lento'
    ELSE 'Fluido'
  END AS estado_transito
FROM eventos_gps_enriquecidos
GROUP BY segmento_id, ventana_5min;
```

```
from pyspark.sql import functions as F

df_trafico = (
  df_eventos_gps_enriquecidos
  .groupBy("segmento_id", "ventana_5min")
  .agg(
    F.avg("velocidad_kmh")
    .alias("velocidad_promedio"),

    F.count("*")
    .alias("cantidad_observaciones")
  )
  .withColumn(
    "estado_transito",
    F.when(
      F.col("velocidad_promedio") < 20,
      "Congestionado"
    )
    .when(
      F.col("velocidad_promedio") < 40,
      "Lento"
    )
    .otherwise("Fluido")
  )
)
```


Fases del ciclo de vida de la ingeniería de datos

Un join combina ...

- Permite agregar a las filas de un DataFrame información almacenada en otro
- Integra columnas de diferentes fuentes relacionando sus filas mediante una clave
- Cada fila de un DataFrame se combina con todas las filas coincidentes del otro.
de acuerdo a la clave

evento_id	segmento_id	velocidad
E01	S01	20
E02	S02	35
E03	S99	18

segmento_id	nombre_via
S01	Av. Italia
S02	18 de Julio
S03	Rivera


```
df_eventos_enriquecidos = (
    df_eventos.join(
        df_segmentos,
        on="segmento_id",
        how="left"
    )
)
```

evento_id	segmento_id	velocidad	nombre_via
E01	S01	20	Av. Italia
E02	S02	35	18 de Julio
E03	S99	18	null

Fases del ciclo de vida de la ingeniería de datos


Tipos de join

INNER JOIN




Solo las coincidencias

LEFT JOIN




Todo A + sus coincidencias con B

RIGHT JOIN



Todo B + sus coincidencias con A

FULL JOIN



Todas las filas de A y B

Fases del ciclo de vida de la ingeniería de datos

Toda consulta tiene un plan y un costo

- Obtener el resultado correcto no significa ejecutar una consulta eficiente
- Factores que determinan el costo
 - Cantidad de datos leídos
 - Columnas seleccionadas
 - Filtros y particiones utilizadas
 - Joins y ordenamientos
 - Movimiento de datos entre nodos
 - Cantidad de consultas concurrentes
- Filtrar temprano y seleccionar únicamente las columnas necesarias reduce el volumen procesado

Fases del ciclo de vida de la ingeniería de datos

Modelado: Niveles

- Obtener el resultado correcto no significa ejecutar una consulta eficiente
- Factores que determinan el costo

Nivel	Pregunta	Ejemplo Waze
Conceptual	¿Qué conceptos necesitamos representar?	Evento GPS, vehículo, segmento vial y estado del tránsito
Lógico	¿Cómo se relacionan y cuál es la granularidad?	Muchos eventos pertenecen a un segmento; una fila de producto por segmento y ventana
Físico	¿Cómo se almacenan y consultan?	Tablas o Parquet, tipos de datos, claves, particiones e índices

Construcción y ejecución de transformaciones

Fases del ciclo de vida de la ingeniería de datos

¿Por qué guardar una transformación?

- Una transformación evita reconstruir la misma lógica en cada consulta
- Una transformación aplica una lógica definida y persiste un resultado para su reutilización.
- Cuando transformamos:
 - No solo calculamos una respuesta → construimos un dataset reutilizable
 - No construimos resultados temporales → los resultados se persisten
 - No respondemos a 1 solo consumidor → puede dar respuesta a varios consumidores
 - No ejecutamos de forma puntual → forma parte de un proceso reproducible

Fases del ciclo de vida de la ingeniería de datos

Batch vs streaming

- La “urgencia” de la decisión determina cuándo transformar
- Que la fuente genere eventos continuamente no obliga a procesarlos en streaming

Transformación batch

- Procesa un conjunto delimitado
- Se ejecuta con una frecuencia
- Minutos, horas o días de latencia
- Informes e históricos
- Recalcular cada noche los patrones históricos de velocidad.

Transformación Streaming o microbatch

- Procesa eventos a medida que llegan
- Siempre está ejecutando
- Segundo o pocos minutos
- Decisiones inmediatas
- Actualizar cada cinco minutos el estado actual de los segmentos.

Fases del ciclo de vida de la ingeniería de datos

Ventanas temporales

- Las ventanas convierten eventos continuos en grupos calculables
- Define qué eventos participan en cada cálculo

Fases del ciclo de vida de la ingeniería de datos

ETL vs ELT

- ETL y ELT cambian el momento en que transformamos
- **ETL: Extraer → Transformar → Cargar**
 - Los datos se limpian y adaptan antes de cargarse en el destino
 - Se utiliza cuando:
 - El destino debe recibir datos ya preparados
 - No se desea conservar información cruda
 - La transformación se realiza en una herramienta externa
- **ELT: Extraer → Cargar datos crudos → Transformar**
 - Los datos se almacenan primero y luego se construyen productos
 - Se utiliza cuando:
 - Se quiere preservar una copia de los datos originales.
 - El almacenamiento permite procesarlos posteriormente.
 - Se necesitan distintos productos a partir de las mismas fuentes.

Fases del ciclo de vida de la ingeniería de datos

ETL vs ELT

- ETL y ELT cambian el momento en que transformamos
- **ETL: Extraer → Transformar → Cargar**
 - Los datos se limpian y adaptan antes de cargarse en el destino
 - Se utiliza cuando:
 - El destino debe recibir datos ya preparados
 - No se desea conservar información cruda
 - La transformación se realiza en una herramienta externa
- **ELT: Extraer → Cargar datos crudos → Transformar**
 - Los datos se almacenan primero y luego se construyen productos
 - Se utiliza cuando:
 - Se quiere preservar una copia de los datos originales.
 - El almacenamiento permite procesarlos posteriormente.
 - Se necesitan distintos productos a partir de las mismas fuentes.

Fases del ciclo de vida de la ingeniería de datos

Selección de herramientas

- El lugar de los datos y la complejidad de la lógica orientan la herramienta

SQL y dbt	Python y PySpark
Datos disponibles como tablas	Datos disponibles como archivos
Filtros, joins y agregaciones	Parsing y limpieza compleja
Transformaciones expresables en SQL	Uso de librerías o lógica personalizada
Modelos, tests y dependencias con dbt	Procesamiento distribuido con PySpark
Warehouse o base analítica	CSV, JSON o Parquet en almacenamiento de objetos

Fases del ciclo de vida de la ingeniería de datos

Actualización del producto

- Cuando persistimos el producto, tenemos que decidir, ¿qué sucede en la siguiente iteración?

Estrategia	Qué hace	Aplicación
Overwrite	Reconstruye todo el producto	Primera versión del laboratorio
Append	Agrega nuevas filas	Nuevas ventanas históricas
Upsert/Merge	Inserta o actualiza por clave	Estado actual de cada segmento
Reemplazar partición	Reconstruye un período afectado	Corrección de eventos atrasados